

CURSO · JORNADA 1 DE 2

Microsoft Foundry

Plataforma para construir IA empresarial

4 horas · master class · caso [Aurora Energía](#)

Qué nos llevaremos hoy

- Entender **qué es Foundry** y cuándo usarlo frente a Azure OpenAI directo.
- Explorar el **catálogo de modelos** y criterios de selección.
- Hacer una primera llamada con **SDK / Responses API**.
- Diseñar prompts con **grounding** y patrón RAG.
- Crear una **knowledge base** con Foundry IQ.
- Ejecutar una primera **evaluación** de calidad y seguridad.

Hilo conductor: asistente interno de operaciones para **Aurora Energía**.

Agenda · 4 h

BLOQUE	MIN	TEMA
M0	15	Bienvenida y caso
M1	30	Qué es Microsoft Foundry
M2	35	Model catalog, despliegues, endpoints y ML
M3	40	SDKs y Responses API
☕	15	Descanso
M4	35	Prompting, grounding y RAG
M5	30	Foundry IQ y knowledge bases
M6	25	Evaluación básica
M7	20	Costes, límites y modelos
M8	10	Cierre



M1 · 30 min

Qué es Foundry

De modelos a plataforma

Foundry en una frase

Microsoft Foundry es la plataforma para **crear, desplegar, evaluar y operar** aplicaciones y agentes de IA sobre Azure.

PIEZA	PARA QUÉ SIRVE
Portal	Proyectos, modelos, agentes, evaluaciones
Model catalog	Más de un proveedor y familia de modelos
Agent Service	Runtime gestionado de agentes
Foundry IQ	Conocimiento empresarial para agentes
Control plane	Seguridad, evaluación, tracing, monitorización

Foundry vs Azure OpenAI

SI NECESITAS...	EMPIEZA POR...
Solo llamadas GPT compatibles con OpenAI	Azure OpenAI endpoint
Multi-modelo y catálogo amplio	Foundry
Agentes con tools y publicación	Foundry Agent Service
Evaluación, tracing y monitorización	Foundry
Knowledge bases gestionadas	Foundry IQ + Azure AI Search

Foundry no sustituye Azure OpenAI: lo amplía como plataforma.

Ideas clave

- **Proyecto** = unidad práctica de trabajo.
- **Modelo** = capacidad de razonamiento o generación.
- **Agente** = modelo + instrucciones + herramientas.
- **Operación** = evaluación, trazas, seguridad y coste.

M2 · 35 min

Modelos y endpoints

Elegir con criterio

Familias de modelos

FAMILIA	ENCAJE
GPT-5 / GPT-4.1	Razonamiento, multimodalidad, tareas complejas
GPT mini / nano	Bajo coste, baja latencia, alto volumen
Claude	Código, contexto largo, razonamiento
Mistral	Multilingüe y propósito general
Phi	Modelos pequeños y eficientes
Llama / abiertos	Control, personalización, open-weight

El mejor modelo es el que cumple calidad, latencia, coste y cumplimiento.

Endpoints que no conviene mezclar



```
https://<resource>.services.ai.azure.com/api/projects/<project>
```

Foundry SDK, Agent Service, tools, proyecto.



```
https://<resource>.openai.azure.com/openai/v1
```

Compatibilidad OpenAI para modelos OpenAI desplegados.

Coste real

- Tokens de entrada y salida.
- Embeddings e indexación.
- Azure AI Search.
- Evaluaciones y red teaming.
- Application Insights / Log Analytics.
- Storage, Cosmos DB y red privada.

Un piloto sin límite de consumo no es un piloto controlado.

ML en Foundry · solo contexto

Foundry también cubre escenarios de **model builders**:

- Modelos abiertos o custom con **managed compute**.
- Infraestructura de Azure Machine Learning para ciertos despliegues.
- Entrenamiento, jobs, pipelines, MLflow y MLOps existen, pero quedan fuera.

En este curso lo tocamos por encima: el foco es IA generativa, RAG y agentes.



M3 · 40 min

Primera app

SDKs y Responses API

Qué SDK uso

SDK/API	USO RECOMENDADO
Foundry SDK	Proyecto, agentes, tools, evaluaciones
OpenAI SDK	Compatibilidad con <code>/openai/v1</code>
Agent Framework	Agentes code-first y multi-agente
REST	Integraciones ligeras y automatización

Para empresa, autenticación con **Microsoft Entra ID** por defecto.

Primera llamada

```
from azure.identity import DefaultAzureCredential, get_bearer_token_provider
from openai import AzureOpenAI

token_provider = get_bearer_token_provider(
    DefaultAzureCredential(),
    "https://cognitiveservices.azure.com/.default"
)

client = AzureOpenAI(
    azure_endpoint=endpoint,
    azure_ad_token_provider=token_provider,
    api_version="preview"
)

response = client.responses.create(
    model=deployment,
    input="Resume que aporta Microsoft Foundry."
)
```

M4 · 35 min

Prompting y RAG

La respuesta necesita evidencia

Prompt empresarial



```
Eres el asistente de operaciones de Aurora Energía.  
Responde en español, con tono profesional.  
Usa solo fuentes conectadas.  
Si no hay evidencia suficiente, dilo.  
Cita documentos o registros usados.  
No reveles datos personales ni secretos.
```

Un prompt es una especificación operativa, no una frase creativa.

Patrones RAG

PATRÓN	CUÁNDO
RAG simple	FAQs y documentación estable
RAG con metadatos	País, área, versión, permiso
RAG evaluado	Calidad y regresiones
Agentic retrieval	Varias búsquedas o fuentes



M5 · 30 min

Foundry IQ

Knowledge bases reutilizables

Foundry IQ en el mapa

CAPA	ENFOQUE
Foundry IQ	Conocimiento empresarial para agentes
Fabric IQ	Semántica sobre datos analíticos en Fabric
Work IQ	Contexto de colaboración de Microsoft 365

Flujo:

1. Conectar Azure AI Search.
2. Añadir fuentes.
3. Configurar retrieval.
4. Probar consultas.
5. Conectar a agente.
6. Evaluar respuestas.

M 6 · 2 5 m i n

Evaluación

Medir antes de publicar

Métricas iniciales

MÉTRICA	PREGUNTA
Groundedness	¿Está fundamentada?
Relevance	¿Responde a lo pedido?
Coherence	¿Es consistente?
Safety	¿Evita contenido inseguro?
Tool accuracy	¿Usa la herramienta correcta?

Tres pruebas manuales no son evaluación.

M7 · 20 min

Producción empieza hoy

Coste, límites, región

Checklist de decisión

- Calidad mínima.
- Latencia máxima.
- Volumen de tokens.
- Región y residencia.
- Compatibilidad de tools.
- Cuotas TPM/RPM.
- Evaluación y monitorización.

Cierre Jornada 1

- Foundry organiza el ciclo completo de IA empresarial.
- El modelo es solo una pieza.
- RAG sin evaluación sigue siendo frágil.
- Mañana convertimos esto en **agentes publicables y gobernados**.